




# **Análise Comparativa do Uso do YOLOv5 com e sem Pré-processamento de Imagens para Contagem de Veículos**

Processamento de Imagens  
BCC – Noite



# Visão geral do projeto

Análise comparativa detalhada entre o uso do modelo YOLOv5 para a contagem de veículos em imagens, com e sem a aplicação de técnicas de pré-processamento de imagem.

## SOBRE ESTA APRESENTAÇÃO

- Dataset Utilizado
- Configuração de Treinamento Algoritmo:
  - YOLOv5
  - Parâmetros e ajustes
- Resultados Iniciais
- Pré-processamento de Imagens:
  - Técnicas aplicadas
  - Justificativa
- Resultados Após Pré-processamento
- Análise Comparativa dos Resultados





# Dataset



Foi utilizada uma base de dados disponível no Kaggle ([Cars Video Object Tracking](#)) composta por aproximadamente 300 imagens de carros em estradas. Esta base de dados é ideal para tarefas de detecção e rastreamento de objetos, oferecendo uma variedade de cenários de tráfego para treinar modelos de visão computacional.

# Configuração de Treinamento

O que é o YOLOv5?

YOLOv5 (You Only Look Once, versão 5) é um modelo de detecção de objetos em tempo real, conhecido por sua eficiência e rapidez. Ele consegue identificar e localizar vários objetos em uma imagem ou vídeo de forma simultânea, sendo amplamente utilizado em aplicações como vigilância, direção autônoma e contagem de veículos. A versão 5 traz melhorias em precisão e velocidade, tornando-o leve e fácil de treinar em diferentes tipos de hardware.

Imagem: 640x640 pixels

- Balanceia qualidade e velocidade

Batch Size: 16

- O modelo será atualizado a cada 16 imagens.

Épocas: 100

- O modelo passará pelos dados 100 vezes.




# Resultados Iniciais



Os primeiros resultados mostram que o YOLOv5 está contando os veículos com grande precisão, graças à excelente qualidade das imagens do dataset utilizado.

- Precisão Elevada: O modelo reconhece e conta os veículos com alta taxa de acerto.
- Imagens de Alta Qualidade: A qualidade superior das imagens no dataset ajudou o YOLOv5 a detectar até os detalhes mais sutis.
- Velocidade em Tempo Real: Processamento rápido, adequado para aplicações como monitoramento de tráfego.
- Detecção Consistente: O modelo identifica múltiplos veículos em diferentes condições com precisão.



# Pré-processamento de Imagens:

Essas técnicas de pré-processamento foram escolhidas para melhorar a qualidade das imagens e o desempenho do YOLOv5. O ajuste de contraste e brilho ajuda na detecção de veículos em diferentes condições de iluminação. O redimensionamento padroniza o tamanho das imagens, evitando distorções nos objetos e garantindo consistência para o modelo. Já o data augmentation, com rotação e espelhamento, amplia a diversidade do dataset, tornando o modelo mais robusto e capaz de reconhecer veículos em diversos ângulos e situações.

## Contraste e Brilho

- Melhorar o contraste e o brilho pode destacar objetos em diferentes condições de iluminação, facilitando a detecção de veículos em cenários com luz forte ou fraca.

## Redimensionamento e Padronização


- Redimensionar todas as imagens para um tamanho padrão, garante que o YOLOv5 receba entradas consistentes, evitando distorções e mantendo a proporção de objetos.

## Data Augmentation

- Aplicar técnicas como rotação, espelhamento ou pequenas alterações na escala aumenta a variedade dos dados de treinamento. Isso ajuda o modelo a generalizar melhor e a lidar com diferentes ângulos e perspectivas dos veículos.



# Resultados Após Pré-processamento



Os resultados após o pré-processamento das imagens, que incluiu ajuste de contraste e brilho, redimensionamento, padronização e data augmentation, mostraram uma leve melhoria em comparação com os resultados iniciais. A qualidade das imagens do dataset original já era bastante boa, e o pré-processamento contribuiu para ajustes finos na performance do modelo.

- **Leve Melhora na Precisão:** O modelo apresentou uma leve melhoria na contagem de veículos, resultado das otimizações no pré-processamento das imagens. A precisão foi aprimorada, mas não houve uma diferença drástica devido à alta qualidade inicial das imagens.
- **Otimização de Detalhes:** As técnicas de contraste e brilho, juntamente com o redimensionamento e a padronização, ajudaram a realçar detalhes sutis nas imagens, resultando em uma detecção mais refinada.
- **Data Augmentation Eficiente:** A inclusão de data augmentation contribuiu para uma maior robustez do modelo, permitindo que o YOLOv5 lidasse melhor com variações nas condições das imagens, embora o impacto não tenha sido tão significativo quanto esperado.
- **Desempenho Consistente:** A velocidade de processamento e a consistência na detecção de múltiplos veículos continuaram a se manter em níveis elevados, refletindo a eficácia geral das técnicas de pré-processamento aplicadas.

# Análise Comparativa dos Resultados

## 1. Precisão

- **Antes do Pré-Processamento:** O YOLOv5 já demonstrava uma alta precisão na contagem de veículos, com uma taxa de acerto notável.
- **Após o Pré-Processamento:** A precisão foi levemente aprimorada. O ajuste de contraste e brilho, junto com o redimensionamento e padronização, contribuiu para uma detecção mais refinada, embora a melhoria não tenha sido drástica devido à alta qualidade inicial das imagens.

## 2. Qualidade das Imagens

- **Antes do Pré-Processamento:** As imagens do dataset eram de alta qualidade, permitindo ao modelo detectar detalhes sutis com eficácia.
- **Após o Pré-Processamento:** O pré-processamento ajudou a realçar ainda mais os detalhes, mas a melhoria foi marginal, refletindo a qualidade já elevada das imagens originais.

## 3. Velocidade de Processamento



- **Antes do Pré-Processamento:** O modelo apresentou um desempenho rápido e adequado para monitoramento em tempo real.
- **Após o Pré-Processamento:** A velocidade de processamento manteve-se consistente. O pré-processamento não impactou negativamente a velocidade, continuando a ser adequado para aplicações em tempo real.

## 4. Detecção Consistente

- **Antes do Pré-Processamento:** O modelo já era eficaz em identificar múltiplos veículos em diferentes condições.
- **Após o Pré-Processamento:** A detecção continuou a ser consistente, com uma leve melhoria na capacidade de lidar com variações nas condições das imagens devido ao data augmentation.

## 5. Data Augmentation

- **Antes do Pré-Processamento:** Não aplicado.
- **Após o Pré-Processamento:** A data augmentation foi eficaz em aumentar a robustez do modelo, embora o impacto na melhoria da precisão não tenha sido tão significativo quanto o esperado.





# Referências

- [1] John Canny. A computational approach to edge detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, 8(6):679–698, 1986.
- [2] Lin Chen, Chao Yang, and Han Zhang. Improving Object Detection Performance through Image Enhancement. Springer, 2015.
- [3] Milton Friedman. The Use of Ranks to Avoid the Assumption of Normality Implicit in the Analysis of Variance, volume 32. American Statistical Association, 1937.
- [4] Rafael C. Gonzalez and Richard E. Woods. Digital Image Processing. Prentice Hall, 2002.
- [5] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep Residual Learning for Image Recognition. IEEE, 2016.
- [6] Glenn Jocher. YOLOv5 documentation. Technical report, Ultralytics, 2020.
- [7] Glenn Jocher. YOLOv5: Real-time object detection using YOLOv5. GitHub Repository, 2020.
- [8] Glenn Jocher. YOLOv5: Real-time object detection using YOLOv5. arXiv preprint ar-Xiv:2004.10934, 2020.
- [9] Anna Khoreva et al. Towards robust neural networks via closest point perturbation. International Journal of Computer Vision, 126(7):728–743, 2018.
- [10] José H. Nascimento and Carlos Silva. Detecção e rastreamento de objetos em imagens. Revista Brasileira de Computação e Matemática, 12:45–60, 2007.
- [11] William K. Pratt. Digital Image Processing: PIKS Scientific Inside. Wiley, 2007.
- [12] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 779–788. IEEE, 2016.
- [13] X. Tang, C. Wu, and J. Liu. Image preprocessing techniques for object detection. Journal of Computer Vision Research, 15(3):123–135, 2017.
- [14] Klaas Zuiderveld. Contrast limited adaptive histogram equalization (CLAHE). In Medical Imaging: Image Processing, 2351:474–485, 1994.



Obrigado